ASTRA

PROCUREMENT INTELLIGENCE

근거를 찾고, 권한을 지키고,
답변의 의심 구절까지 확인하는 조달 검토 시스템

나라장터 공개 공고 · 합성 기업 자료 · 권한형 하이브리드 RAG · 구절 단위 환각 검증

DATA

3개월 수집과 51건 원문 검수

RAG

223문서 · 3,275청크

EVAL

300문항 · 생성답변 295건

ko-LettuceDetect / ASTRA · B1조 최종발표

2026.10.02

프로젝트 결과를 먼저 숫자로 요약하면

수집·검수·색인·생성은 완료 범위가 있고, 탐지 성능은 평가 진행 중이다

137,745
공고 행
4~6월 · 차수 포함

246,797
사용 가능 첨부
전체 285,252개 중 87%

51
검수 표본
SW 개발 32 · 운영 19

223 / 3,275
문서 / 청크
L1·L2·L3 로컬 색인

300
평가 문항
합성 기업 5곳 × 60

295 + 5
생성 / 차단
실제 답변 295 · 정상 차단 5

현재 발표 가능한 결론

- 데이터와 정본 답변, 근거 연결, 권한 차단은 재현 가능한 산출물로 보존
- KLUE·XLM-R·BGE-M3의 295답변 전체 비교 수치는 아직 확정하지 않음
- 25문항 사람 검수는 접수 완료, 최종 승인과 학습 내보내기는 pending

근거: 3개월 통합현황 · index_manifest · QA validation · workstation final_summary

발표 흐름

문제 → 데이터 → 평가 설계 → 권한형 RAG → 생성·탐지 → 시연 순으로 연결한다

01

왜 조달 검토가 어려운가

정정·충돌·누락·권한

02

어떤 데이터를 구축했는가

3개월 수집·51건 검수·합성기업

03

무엇으로 평가하는가

300 Q-A-R·정본·근거

04

어떻게 답하는가

ACL·하이브리드 검색·로컬 LLM

05

어떻게 오류를 찾는가

규칙·토큰 분류·사람 검수

06

현재 어디까지 왔는가

데모·검증·남은 과제

핵심 질문: “이 답은 누가 볼 수 있는 어떤 문서의 어느 구절에서 나왔는가?”

부록에는 재현성 검사, 세부 수치 원장, 정확성 제한을 별도로 수록

입찰 검토는 “문서 검색”보다 복잡하다

같은 사업 안에서도 문서 버전·조건 범위·기업 자료·권한을 함께 해석해야 한다

버전 정정공고에서 업종 코드와 일정이 함께 변경

범위 금액·실적·인력 조건이 문서마다 다른 범위를 가짐

충돌 공고문과 RFP의 공동수급·사업기간 표현이 병존

증빙 회사 실적 금액이 있어도 증빙이 missing이면 확정 불가

권한 공개 공고와 원가·마진 자료의 공개 범위가 다름

답변 근거가 있어도 모델이 숫자·주체·예외를 바꿀 수 있음

ASTRA는 검색 결과가 아니라 “권한이 적용된 근거 + 답변 + 검증 상태”를 하나의 단위로 다룬다

공식 사례와 51건 원문대조에서 확인한 범위만 사용

실제 문서에서는 “정답 하나”가 바로 나오지 않는다

공식 의결문과 51건 원문대조에서 확인한 대표 사례

1. 신청인의 부당한 적격심사평가로 인한 낙찰자 선정을 취소해 달라는 신청은 심의 안내한다.
2. 피신청인에게, 향후 유사 입찰공고 시 공고문 등을 통해 입찰자에게 기술능력 평가 기준 등 적격심사 방법에 대한 제반 정보를 구체적이고 명확하게 제공할 것을 의견표명한다.

평가 기준 명확화 요구

향후 유사 공고에서 기술능력 평가 기준 등 적격심사 방법을 더 구체적으로 제공하라는 공식 의견.

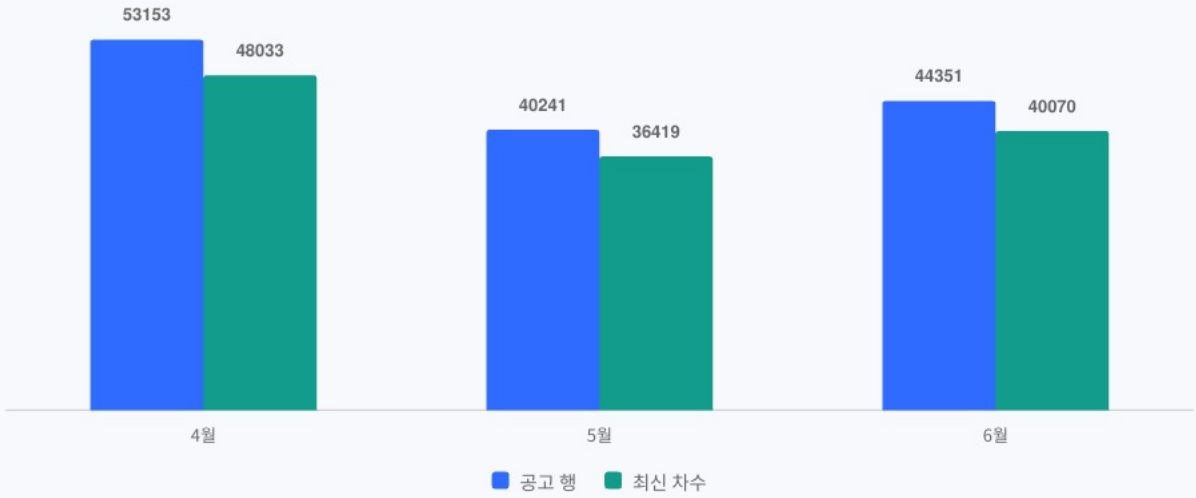
원문대조 사례	문서에 함께 존재한 값	처리
경민대 예산	165,000,000원 / 메타 181,500,000원	출처 분리
동아보건대 마감	11:00 / 10:00	단일값 보류
천안 사업기간	착수일부터 / 계약일부터 120일	기산점 보류
강릉 예산	58,000,000원 / 영향평가 80,000,000원	범위 구분

12개 쟁점 공고 재대조

첨부 미확보 2 · 원문 문제 확인 6 · 일부 해소 4

3개월 동안 137,745개 공고 행을 수집·변환했다

월별 수집량과 최신 차수, 첨부 활용률을 분리해 기록



285,252
전체 첨부
다운로드·파일 실재 기준

246,797
사용 가능
어댑터 판정 87%

3,301
재파싱 후 실패
4월 1,408 · 5월 144 · 6월 1,749

124,522
최신 차수 공고
중복 차수 제거 관점

저장 원칙 raw / parsed / jsonl과 해시·실패 사유를 분리해 재개 가능하게 보존

모든 첨부를 성공으로 세지 않고, 사용할 수 없는 문서와 실패 원인을 별도 기록

근거: project-docs/데이터현황/3개월_통합현황.md · 2026.09.11 확정

완전 공고 비율과 요건 구조를 보고 “용역”을 선택했다

완전 공고 = 공고문 + 제안요청서 또는 과업·규격서



업무구분	공고	사용 가능 문서	완전 공고	비율
용역	50,717	102,702	28,852	57%
물품	32,673	66,298	14,145	43%
공사	38,839	73,038	8,082	21%

메인 분야 선택

SW 및 시스템 개발 984건 + 운영·유지관리 681건
실적·인력·인증·단가 네 축을 비교하기에 적합

분야는 가상 기업 서사가 아니라 데이터 규모·문서 완성도·요건 구조를 기준으로 결정

근거: 2026-04to06 워크스테이션 통합 sector report

51건 표본은 월과 분야를 고정해 구성했다

4·5·6월 각 17건, SW 개발 32건과 운영·유지관리 19건

4월 17건
월별 편중을 막기 위해
동일 수량 선정

→

5월 17건
공고문·RFP·과업서
확보 여부 확인

→

6월 17건
요건 시트 15열로
동일 구조 정리

→

통합 51건
SW 개발 32
운영·유지관리 19

검수 대상	정리 항목	보존 방식
공고·첨부	공고번호·기관·예산·기한	원본 경로·해시
참가 조건	업종·지역·직접생산·공동수급	출처와 문구
평가 조건	실적·인력·인증·배점	없음/미확인 구분
쟁점	문서 충돌·추출 불완전	보류 사유

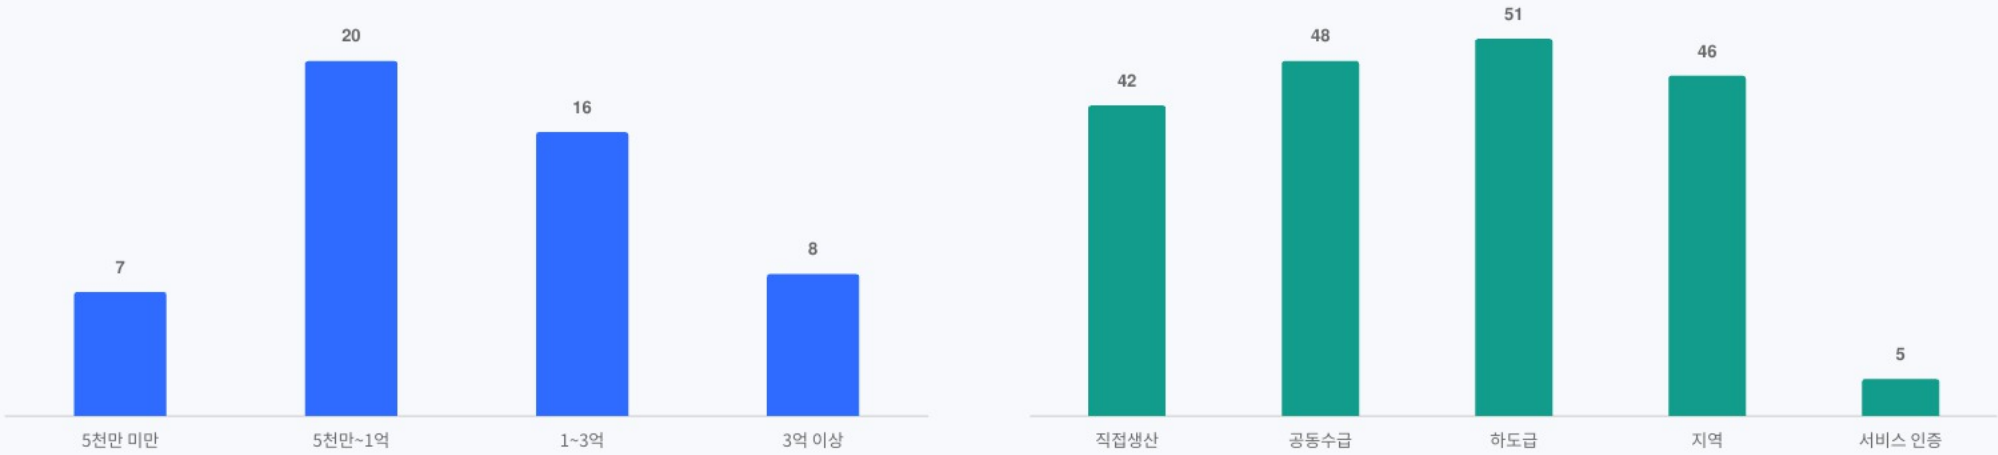
검수 결과

- 51건 · 15열 · 빈 요건 셀 없음
- 12개 쟁점 공고 원문 재대조
- 나머지 39개 공고 셀은 유지
- 원문·전체 추출 텍스트는 Git 제외

표본은 전체 나라장터를 대표하는 확률표본이 아니라 파일럿 구축용 검수 표본

51건 안에서도 금액과 조건 조합이 다양하다

조건 수는 “언급 여부”이며 필수·허용·금지 판정 수가 아니다



해석 주의 **“공동수급 48건”은 공동수급이라는 조건이 등장했다는 뜻이며, 48건 모두 허용한다는 뜻이 아니다.**

단순 키워드 집계에서 멈추지 않고, 답변 단계에서는 허용·금지·예외와 근거 범위를 다시 확인

원문 재대조는 “충돌을 없애는 작업”이 아니었다

문서 차이를 숨기지 않고 답변 가능한 범위와 판단 보류 범위를 분리

상태	건수	대표 사례	처리 원칙
첨부 미확보	2	법원센터·부산올랭	RFP 확보 전 없음으로 단정 금지
원문 문제 확인	6	천안·경기·첨단로봇·동아·강릉 등	양쪽 문서와 적용 범위 병기
일부 해소	4	충남 ESG·경민대·승차권·광양	확인된 항목만 수정, 잔여 쟁점 유지

01 출처 고정

공고문·RFP·과업서·메타데이터를 구분

02 범위 고정

예산·실적·배점의 적용 대상을 분리

03 보류 유지

정정공고·발주기관 답변이 없으면 단일값 확정 금지

04 추출 한계

표·수식 경계가 깨지면 임의 복원하지 않음

판단 보류는 실패가 아니라 원문이 허용하는 정확한 상태

12개 쟁점 공고 재대조 · 파일 해시는 별도 식별 JSON에 보존

가상 기업 5곳은 51건의 조건을 비교하기 위한 기준 회사다

실제 업체 정보가 아니라, 충족·미충족·자료부족 사례를 유지하는 합성 원장

5	45	16	111	45
가상 기업	인력 레코드	프로젝트	증빙 레코드	문서 템플릿

원장 설계 원칙

- **고정 사실** — 공고마다 회사 주소·면허·실적을 바꾸지 않음
- **증빙 상태** — 금액이 있어도 missing 증빙은 인정으로 승격하지 않음
- **격리** — 평가 기대답과 라벨을 검색 문서에 복사하지 않음
- **경계 사례** — 69,999,999원 vs 70,000,000원처럼 임계값을 보존
- **시간 상태** — 인증 유효기간·재직·기존 배치·잔여 FTE를 기준일로 계산
- **보안** — L2와 L3를 분리하고 tenant·역할을 문서 메타데이터로 고정

합성 데이터를 사용해 실제 기업 기밀 없이도 권한·경계값·자료부족 시나리오를 반복 검증

기업마다 강점과 제약을 다르게 설계했다

모든 회사를 쉽게 통과시키지 않고, 실제 검토처럼 자료부족과 조건 미충족을 남김

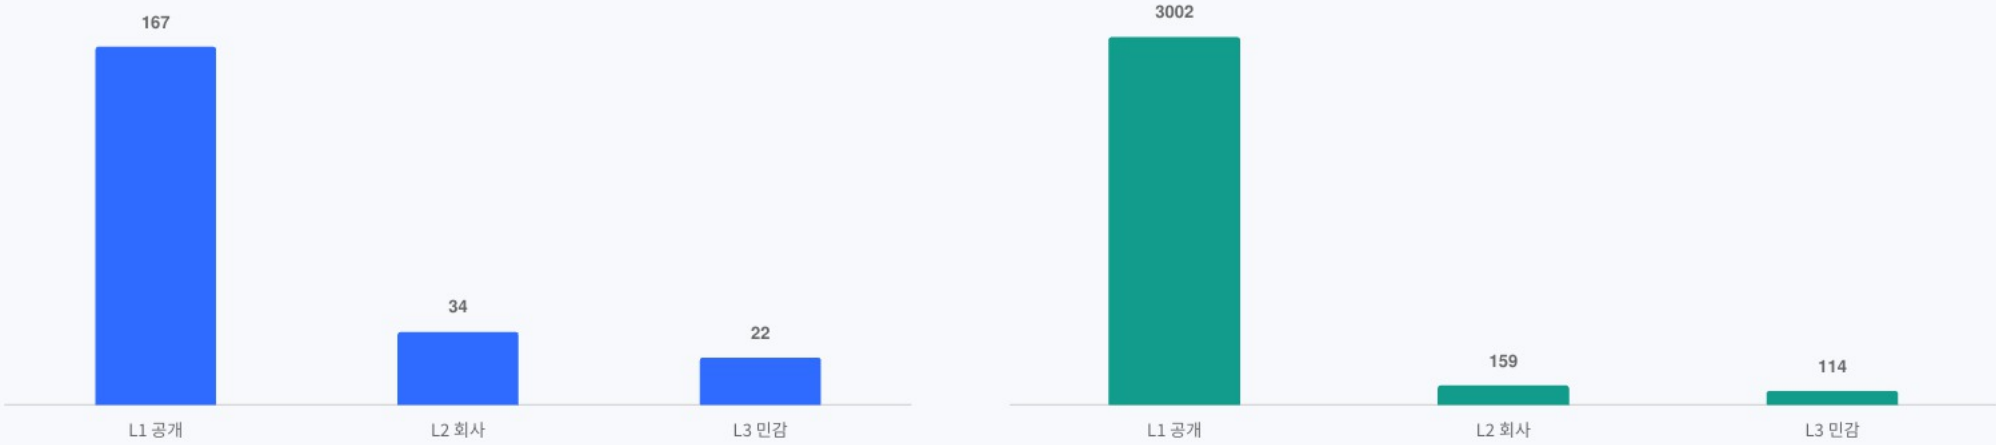
기업	규모·특성	주요 강점	의도적으로 유지한 제약
C01 한빛IT	소기업 · 웹/포털	개발 실적·개발 인력	0036 미보유 · 실적 증빙 missing
C02 해온시스템	소기업 · 유지관리	운영 경험·현장 대응	직접생산 만료 · 0.5 FTE 기존 배치 · 확약서 없음
C03 인우블록	소기업 · 소규모 개발	다역할 인력 구성	실적 증빙 missing · 공동수급 실패 사례
C04 누리클라우드	소기업 · 클라우드	클라우드 운영 인력	회사 ISO와 서비스 CSAP 분리 · 공급권한 없음
C05 새온에너지SW	중기업 · 산업 SW	장비 연계·제조 도메인	일부 실적 증빙·전체 장비 견적 없음

생성 결과 **C01 5문서·27청크 + C02~C05 36문서·140청크 · 공통문서와 공고별 문서를 구분**

제약을 없애지 않고 보존했기 때문에 “가능·불가·자료부족”을 모두 평가할 수 있다

L1·L2·L3로 문서 성격과 검색 범위를 분리했다

검색 코퍼스 223문서·3,275청크의 실제 구성



L1 나라장터 공고·RFP·과업지시서
모든 인증 사용자

L2 자기 회사 실적·인력·인증·배치안
bid analyst 이상

L3 원가·마진·견적·투찰 검토
cost analyst / approver

보안 등급은 문서의 성격, ACL은 로그인 사용자가 실제로 검색할 수 있는 범위를 결정

L2·L3는 실제 기업 자료가 아닌 합성 내부 자료

300개 Q-A-R은 검색 DB가 아니라 평가 기준이다

질문·기대답·근거를 검색 문서와 분리해 생성 입력 누출을 막음

51건 요건
공고별 참가·실적·인력·인증·금액·일정

→

가상 기업 5곳
회사별 강점·제약과 증빙 상태

→

회사당 60문항
5 × 60 = 300 Q-A-R

→

근거 연결
공고 발췌 299개
회사 청크 연결 237개

검증 항목	결과	의미
질문 ID	300개 고유	회사별 60개
공고	51개	검수 표본 전체 연결
신규 평가 문서/청크	15 / 106	평가 전용 자산
기존 회귀	v1/r1 hash·C01 byte 재생성 통과	기존 자료 변경 방지
실제 답변/span	0 / 0	평가 데이터 생성 시점에는 미포함

누출 방지

- 기대답·라벨은 검색 문서에서 제외
- 평가 파일은 별도 경로에 격리
- 질문과 생성 답변을 같은 정본 ID로 연결
- 사람 승인 전 gold 성능으로 부르지 않음

문자열·참조 검사는 의미적 정답이나 검색 성능 보증이 아님

ASTRA는 구축 파이프라인과 질의 파이프라인을 분리한다

정본을 한 번 구축하고, 질의마다 권한·검색·생성·검증을 순서대로 적용



구축 시점과 질의 시점을 분리해 같은 정본·버전·권한 정책을 재사용

사용자 질문은 여섯 단계를 거친다

권한 밖 문서는 검색 결과를 만든 뒤 숨기는 것이 아니라 검색 전에 제외

1 **공고·회사 선택**

질문과 기준일 입력

2 **세션 검증**

tenant·회사·역할·시나리오

3 **ACL 필터**

허용 문서 ID만 남김

4 **하이브리드 검색**

키워드+벡터 순위 결합

5 **로컬 답변 생성**

선택 근거 최대 4개 사용

6 **검증·표시**

규칙·탐지·근거 UI

클라이언트가 보낸 역할 문자열이 아니라 서버가 확인한 세션과 멤버십이 검색 범위를 결정

실제 생성에 사용한 근거와 탐지 입력 근거를 동일하게 유지

역할·회사·tenant·시나리오를 함께 검사한다

같은 역할이어도 다른 회사 문서나 승인되지 않은 시나리오는 검색하지 못함

역할	L1 공개	자기 회사 L2	자기 회사 L3	대표 업무
viewer	허용	차단	차단	공개 공고 확인
bid_analyst	허용	허용	차단	실적·인력·인증 검토
cost_analyst	허용	허용	허용	원가·견적 검토
bid_approver	허용	허용	허용	투찰 승인 검토

서버 검사 항목

- authenticated = true
- membership_active = true
- tenant_id 일치
- company_id 일치
- role이 문서 allowed_roles에 포함
- scenario_id와 기준일 유효

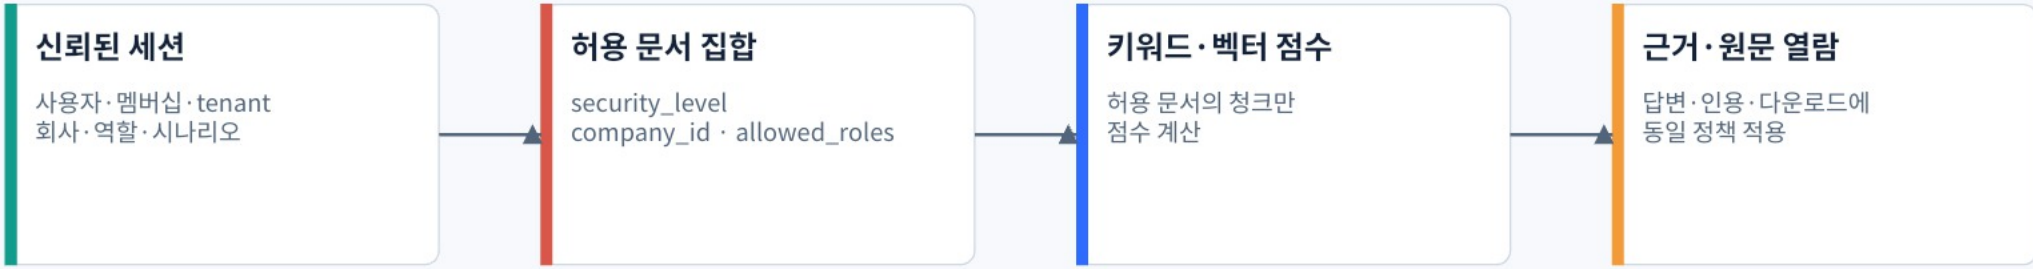
차단은 정상 결과다

평가 300건 중 5건은 권한 정책에 따라 LLM을 호출하지 않고 access_denied로 기록했다.

차단 답변을 빈 답변이나 모델 실패로 집계하지 않는다.

권한 필터는 검색 순위 계산보다 먼저 실행된다

전역 검색 후 화면에서 숨기는 방식보다 데이터 경계를 앞단에서 강제



검사한 실패 유형	기대 동작
타 tenant / 타 회사 문서 ID	요청 거부 또는 후보에서 제거
L2에 L3 내용 혼입	정본·스키마 검사 실패
기대답·라벨 필드 오염	생성·색인 검사 실패
잘못된 offset / 답변 hash	검수·데모 자료 검증 실패

검증 자산

- 가상기업 접근 규칙 20건 통과
- C01 7개 사용자 상황 × 27청크 = 189개 메타데이터 검사
- 데모 오류 주입 검사에서 L2 혼입·타회사 ID·기대답 유입 거부

색인은 정본·버전·문자 위치를 함께 보존한다

긴 문서는 의미 단위 parent chunk를 만들고 임베딩 window와 생성 근거를 분리

문서 정본

document_id · version · SHA-256
원본 binary hash 대조

Parent chunk

최대 1,800자 · overlap 240자
회사 entity는 온전하게 재사용

Offset

Unicode code point
[start, end) · LF 기준

실패 분리

읽을 수 없는 문서 16개
이번 색인에서 제외·사유 보존

등급	문서	청크	문서당 평균 청크
L1	167	3,002	18.0
L2	34	159	4.7
L3	22	114	5.2
합계	223	3,275	14.7

생성 근거 보존 원칙

- 모델 입력에는 검색으로 선택된 parent 원문 사용
- 탐지기도 당시 생성에 사용한 동일 근거를 입력
- 사후 전체 원문은 별도 진실성 검토에만 사용
- 정본 답변과 근거 hash가 다르면 resume 중단

3,275개 parent 청크를 7,195개 임베딩 window로 확장했다

긴 문맥은 잘라 버리지 않고, window 최대 유사도를 parent 순위에 사용

Parent text
3,275개
생성용 원문 유지

→

Token window
460 token
stride 420

→

Embedding
multilingual-e5-small
384차원 · L2 정규화

→

Parent score
window 최대 점수
parent 최대 3 window

7,195	512	8	4	1,379.6초
embedding windows	token limit	batch size	CPU threads	index build

모델 고정 intfloat/multilingual-e5-small · revision 614241… · MIT · query:/passage: prefix · truncation=false

문서 임베딩은 CPU float32로 구축 · 생성 모델 GPU 실행과 별도

키워드와 의미 검색을 RRF로 결합한다

코드·금액·날짜는 정확히, 표현이 다른 문장은 의미로 보완

Lexical

한국어 2글자 부분어
영문·숫자 exact token
BM25 형태 점수

Dense

multilingual-e5-small
질문과 문장 의미 유사도
window 최대 parent 점수

RRF 결합

rank 기반 결합 · k=60
상위 parent 최대 6개
생성에는 우선 최대 4개

$$RRF(d) = \Sigma\ 1 / (60 + rank_m(d))$$

검색기의 점수 척도를 직접 섞지 않고 각 순위를 안정적으로 합산

“8111159901”
키워드가 코드 경계를 보존

“장애 방문과 복구시간 차이”
벡터가 유사 표현을 보완

“1억원 이상 실적”
숫자 exact + 의미 문맥을 함께 확인

답변은 외부 API 없이 로컬 GPU에서 생성했다

Qwen3-4B GGUF 모델을 한 번 로드하고 여러 문항을 배치·재개 방식으로 처리

Qwen3-4B
생성 모델

Q4_K_M
양자화

4,096
context

768
max tokens

37 / 37
GPU offload layers

5,588 MiB
peak GPU memory

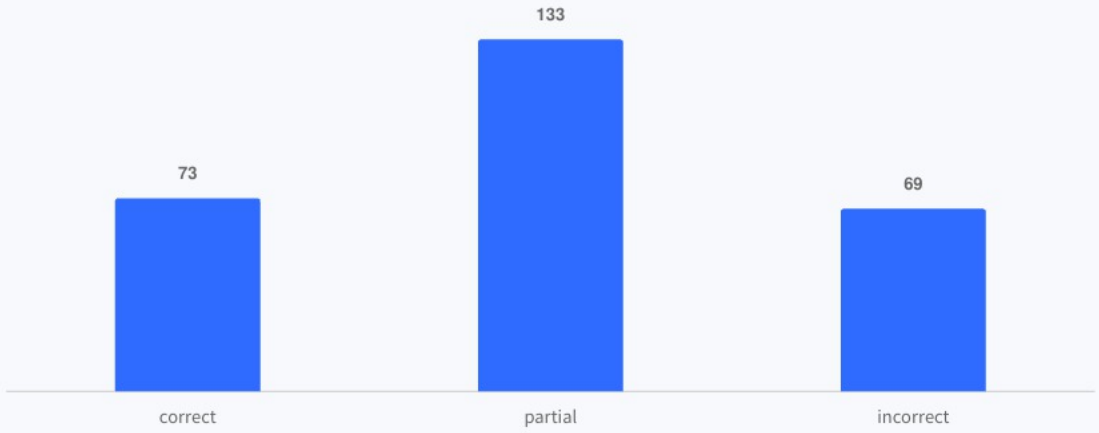
설정	값	목적
temperature / top_p / top_k	0.7 / 0.8 / 20	일관성과 표현 다양성 균형
max evidence chunks	4	근거 범위 제한
batch / ubatch	512 / 512	워크스테이션 처리량 조정
backend / device	Vulkan / RTX A5000	37개 layer 전부 offload
외부 API	사용 안 함	회사 자료 전송 경계 통제

모델·revision·파일 SHA-256·프로필을 environment.json에 기록

정본 답변 295건과 정상 차단 5건을 보존했다

에이전트 검토 분포는 탐색 결과이며 독립 정확도나 사람 gold 성능이 아니다

295	5	4	1	6
생성 답변	**정상 접근 차단**	**잘림 답변**	**인용번호 오류 답변**	**선택 재시도 ID**
기존 25 + 신규 275	LLM 호출 없음	신규 275 중	신규 275 중	repair attempt



이 분포를 정확도로 부르지 않는 이유

- 질문마다 조건과 난도가 섞여 있음
- 실행 후 라우팅 repair에 노출된 개발 자료
- 에이전트 검토 rubric이며 사람 승인 아님
- 구절 단위 환각 라벨링은 당시 수행하지 않음

correct 73 · partial 133 · incorrect 69

원본 25답변은 보존 · 답변·prompt·record hash로 선택 결과 고정

환각 탐지는 답변을 실제 생성 근거와 직접 대조한다

답변 전체를 보되, 모델·규칙·인용 검사를 서로 다른 신호로 유지



판정 유형	의미	평가에서의 처리
CONTRADICTION	근거와 명시적으로 모순	환각 구절
UNSUPPORTED	근거가 답변 주장을 지지하지 않음	환각 구절
UNCERTAIN	근거 부족으로 확정 불가	보류 · 정상으로 계산 금지
CITATION_ERROR	인용번호·위치 오류	내용 환각과 별도
QUALITY_ONLY	잘림·형식·문장 품질	탐지 성능과 별도

25문항 사람 검수는 접수됐고, 88개 구절 조정안을 만들었다

최종 사람 승인 전이므로 학습용 gold나 독립 테스트로 사용하지 않음

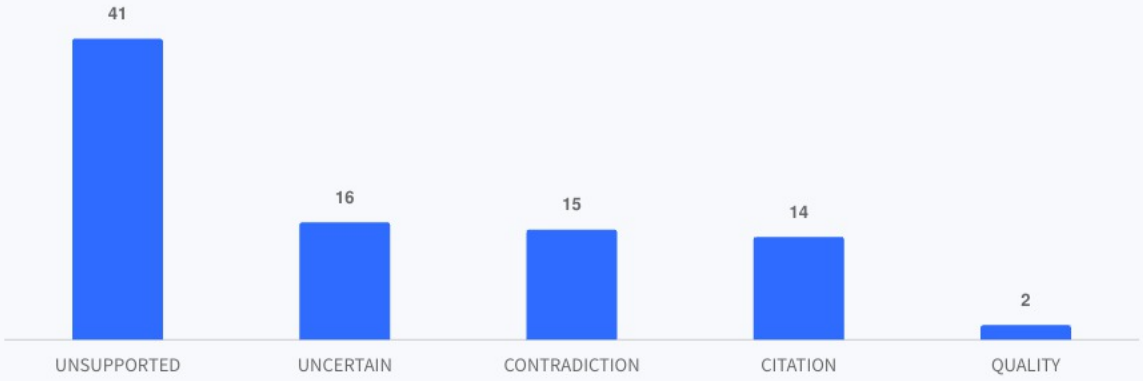
25
검수 문항
팀원별 서로 다른 문항

68
기존 구절
동의 65 · 수정 3

88
조정안 구절
추가·수정 포함

79
근거 청크 참조
read-only index hash 대조

pending
최종 승인
training_ready=false



조정 결과

처리	구절
제안 수용	70
보류	16
품질만	2

문항 결정

결정	문항
동의	12
수정 제안	12
재검토	1

검수자 간 중복 문항이 없어 inter-annotator agreement는 계산할 수 없음

원 제출 의견은 보존 · 에이전트 조정안과 사람 최종 승인 분리

KLUE·XLM-R·BGE-M3 비교는 같은 입력 계약으로 진행한다

3모델 × 생성답변 295건 = 885 추론 슬롯, 차단 5건은 별도 무호출 검증

후보	입력 계약	평가 상태	발표 가능한 결론
KLUE	질문·근거 window·답변 token	평가 진행 중	운영 주력 후보, 우열 미확정
XLM-R	동일 정본·offset·window	평가 진행 중	KLUE 오류 보완 가설 때 비교
BGE-M3	동일 정본·offset·window	평가 진행 중	추가 비용 대비 개선 확인 필요

답변 단위

TP / FP / FN / TN
정밀도·재현율·F1

구절 단위

문자 P/R/F1
exact-span F1

운영 단위

자동 판정률·보류율
검사 커버리지

분석 단위

회사·오류 유형·길이
시간·VRAM·실패

현재는 “평가 설계와 입력 정합성 완료”, 성능 숫자는 완료 후 별도 반영

미승인 라벨 기준 점수는 잠정 평가로만 표시

오류는 결론·근거·인용 위치에서 다르게 발생한다

25문항 조정안의 대표 사례 · 최종 사람 승인 pending

CONTRADICTION

“인천을 제외해도 된다”

부정 범위가 뒤집힘

근거는 서울·경기(인천 포함)라고 명시

답변 ●

근거 ●

UNSUPPORTED

“기존 배치의 잔여 FTE가 0.0”

주체 연결이 근거에 없음

다른 인력의 값을 재사용

답변 ●

근거 ●

CITATION_ERROR

답변에 “[3]” 표시

내용과 별개로 인용 위치 오류

실제 prompt 인용은 [1], [2]만 존재

답변 ●

근거 ●

탐지기가 해야 할 일: 문장 전체를 틀렸다고 지우는 것이 아니라, 바뀐 조건·없는 주체·잘못된 인용 위치를 표시

사례는 모델 예측을 정답으로 복사하지 않고 답변과 실제 생성 근거를 대조해 작성

통합 평가는 검색·생성·라벨·탐지를 분리해 보고한다

자동 검사 통과와 모델 성능 확정은 같은 상태가 아니다

평가 축	현재 확인 범위	상태	다음 검증
데이터	137,745행·285,252첨부·51건 표본	수집·변환·원문대조 완료	누락 RFP 2건 확보
색인	223문서·3,275청크·7,195 window	해시·offset·권한 메타 확인	운영 index 연결
생성	295답변·정상 차단 5	정본·선택·hash 고정	질문 충족도·오류 유형 승인
사람 라벨	25문항·88 조정안 구절	접수·조정 완료 / 승인 pending	최종 승인·training export
탐지	3모델 × 295 = 885슬롯	입력 동결 / 평가 진행 중	P/R/F1·보류·커버리지
UI	51공고·저장답변·L1 로컬 질문	정적/실행 모드 검증	운영 인증·L2/L3 자유질문

재현 가능한 자산 완료

생성 답변 보존 완료

사람 gold 라벨 대기

탐지 성능 평가 중

성능이 끝나지 않은 칸은 수치 대신 상태와 필요한 다음 검증을 명시

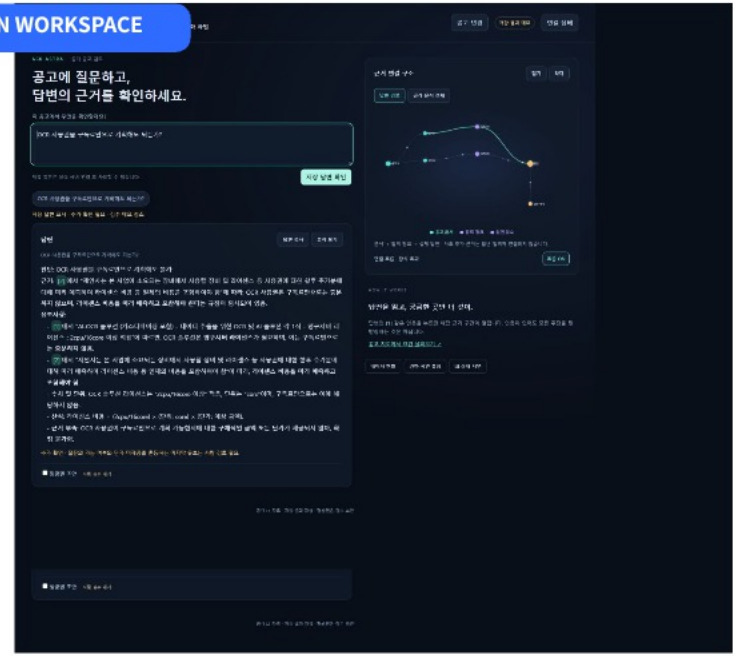
데모에서는 답변보다 “근거 연결”을 먼저 보여준다

51개 공고 탐색 → 질문 → 실제 입력 근거 → 답변 → 의심 구절 순서

EVIDENCE OBSERVATORY



QUESTION WORKSPACE



1 지도에서 공고 선택

2 질문 입력·모드 확인

3 답변의 인용 클릭

4 원문 근거·의심 구절 확인

저장 결과 모드 · L1 실제 질문 모드 · 탐지 미실시 상태를 화면에서 구분

구현 자산은 남았고, 성능 검증은 계속된다

프로젝트의 의미는 좋은 숫자 하나가 아니라 추적 가능한 데이터·근거·권한·검증 구조

완료한 자산

- 3개월 수집·변환 파이프라인
- 51건 원문 검수와 쟁점 기록
- 합성기업 5곳과 L2/L3 자료
- 223문서·3,275청크 색인
- 평가 300문항·정본 답변 295건

검증한 구조

- tenant·회사·역할 기반 ACL
- BM25 + E5 + RRF 검색
- Qwen3-4B 로컬 GPU 생성
- 정본·prompt·근거 hash 고정
- 25문항 사람 검수 접수·조정

남은 과제

- 25문항 최종 사람 승인
- 295답변 전체 탐지 비교
- 운영 인증·인가·감사로그
- L2/L3 자유질문 Live 연결
- 독립 평가 분할과 운영 지표

AI가 입찰을 대신 확정하는 시스템보다, 사람이 근거와 오류 가능성을 더 빨리 확인하는 시스템

발표 후 성능 수치가 확정되면 모델 비교·통합 평가 슬라이드만 갱신 가능

APPENDIX A · 재현성과 오류 주입 검증

각 검사는 구조·계약을 확인하며 자유서술 전체의 정확성을 보장하지 않는다

구간	검사 규모	주요 검사	결과
가상기업 마스터	32 unit tests	스키마·날짜·인증·VAT·지분·참조	통과
C01 문서	24 + 32 = 56 tests	청크 offset·기대답 오염·L2/L3 혼입	통과
접근 규칙	20 cases / C01 189 metadata checks	타 tenant·역할·비활성 사용자	통과
RAG 워크스테이션	158 기존 + 9 신규 offline regressions	resume·hash·권한·retrieval 계약	통과
공개 데모	Python 9 + JS 구조 검사	타회사 ID·잘못된 offset·답변 교체·XSS	통과
로컬 통합	17 + 9 + 7 + 8 프로토콜/회귀	모델→detecting→done·취소·미설정	통과

검사 경계 **자동 검사는 파일 구조·정본·계산·프로토콜을 검증한다. 검색 Recall, 답변 정확도, 탐지 F1과 운영 보안은 별도 평가가 필요하다.**

테스트 수는 서로 다른 단계의 실행 기록이며 중복을 합산한 총 테스트 수로 발표하지 않음

APPENDIX B · 발표 수치 원장

본문 수치의 분모·정의·상태를 한 장에서 재확인

항목	값	분모·정의	상태
공고 행 / 최신 차수	137,745 / 124,522	4~6월 · 공고 차수 포함/최신	확정
첨부 / 사용 가능	285,252 / 246,797	어댑터 사용 가능 87%	확정
완전 공고	용역 28,852 · 물품 14,145 · 공사 8,082	공고문 + RFP/과업·규격서	확정
표본	51	4·5·6월 각 17	검수 완료
합성 원장	5사 · 45명 · 16프로젝트 · 111증빙	실제 기업 자료 아님	자동검사 완료
색인	223문서 · 3,275청크	L1 167/3002 · L2 34/159 · L3 22/114	로컬 색인
임베딩	7,195 window · 384차원	E5-small · 460/420 token	구축 완료
평가	300문항 · 5사×60	검색 코퍼스와 분리	구조 검증
생성	295답변 + 차단5	Qwen3-4B 로컬 GPU	정본 고정
사람 검수	25문항 · 88조정안 구절	최종 승인 전	pending
탐지 비교	885 슬롯	3모델 × 295답변	평가 진행 중

확정·검수 완료·구조 검증·pending·평가 진행 중을 같은 의미로 읽지 않음

APPENDIX C · 발표에서 넘지 않는 주장 경계

구현 사실과 성능 결론을 분리해야 결과가 재현 가능하다

말할 수 있음	말하면 안 됨
51개 공고와 223문서의 연결 구조를 구축	전체 나라장터에 대한 검색 성능을 검증
295개 정본 답변과 생성 근거를 보존	RAG 정확도가 특정 비율이라고 주장
권한 정책으로 5건을 모델 호출 전에 차단	운영 인증·인가와 보안 감사를 완료
25문항 사람 의견을 접수하고 88구절 조정안 작성	25문항을 독립 gold 테스트로 사용
3모델 × 295답변 평가 구조를 준비	KLUE·XLM-R·BGE-M3 성능 우열 확정
저장 결과와 L1 로컬 질문 UI를 검증	L2·L3 자유 질문이 운영 DB와 연결

데이터
분모와 집계 기준 확인

모델
학습·개발·평가 분할 확인

사람
승인자·시점·대상 구절 기록

운영
인증·로그·실시간 모드 별도 검증

미완료 결과는 자리와 평가 방법만 설계하고 “평가 진행 중”으로 표시