ASTRA 답변 생성 LLM 비교 평가

공공입찰 RAG 파이프라인 모델 선정 보고서

도입 조건: 가용 메모리 10GB 이하

2026 년 9 월

1. 결론

현행 Qwen3-4B 를 유지할 것을 권고한다.

10 개 모델을 비교한 결과, 품질이 더 나은 모델은 존재하나 가용 메모리 10GB 조건을 만족하지 못한다. 조건을 만족하는 모델 중에서는 현행 모델이 가장 우수하다.

모델	맞는 답	틀린 답	메모리	판정
Qwen3-8B	86.9%	11.0%	10.73GB	메모리 초과
Qwen3-4B (현행)	**76.9%**	**22.1%**	**8.93GB**	**조건 충족 · 1 위**
Llama-3.1-8B	76.6%	19.3%	미측정	조건 충족 · 2 위

Qwen3-8B 는 현행 대비 맞는 답이 10.0%p 많고 틀린 답이 절반이지만, 메모리 10.73GB 로 기준을 0.73GB 초과한다. 메모리를 증설하면 교체 이득이 크다.

2. 어떻게 비교했나

비교의 공정성을 확보하기 위해, 모델 이외의 모든 조건을 동일하게 고정했다.

2.1 후보 10 종

크기가 다른 모델을 계단식으로 배치해 "성능 차이가 모델 크기 때문인지 모델 자체의 품질 때문인지"를 구분할 수 있게 했다. 국산 모델과 해외 모델을 함께 넣었고, 상업적으로 사용 가능한 라이선스만 선정했다.

모델	크기	라이선스	선정 이유
Qwen3-1.7B	1.7B	Apache-2.0	크기 사다리 최하단
Gemma-3-1B	1B	Gemma Terms	1B 급 해외 모델
Kanana-1.5-2.1B	2.1B	Apache-2.0	2B 급 국산(카카오)
Mi:dm-2.0-Mini	2.3B	MIT	2B 급 국산(KT)
Qwen3-4B	**4B**	**Apache-2.0**	**현행 모델(비교 기준)**
Gemma-3-4B	4.3B	Gemma Terms	4B 급 해외 모델
Qwen3-8B	8.2B	Apache-2.0	8B 급 · 크기 사다리
Kanana-1.5-8B	8B	Apache-2.0	8B 급 국산
Llama-3.1-8B	8B	Llama 3.1	8B 급 국제 기준선
Qwen3-14B	14.8B	Apache-2.0	품질 상한 확인

2.2 공통 조건

조건	값	왜 고정했나
양자화	Q4_K_M	모델 파일 압축 방식. 다르면 용량과 품질이 달라짐
문맥 길이	24,576 토큰	근거 문서가 잘리지 않는 길이로 통일
온도(temperature)	0	같은 입력에 항상 같은 답이 나오게 고정
난수 시드	고정	재실행해도 동일 결과
추론 모드	끔	모델별 기본값 차이 제거

현행 운영 설정은 문맥 4,096 토큰이었다. 이는 CPU 메모리 제약 때문이며 모델의 한계가 아니므로, 비교에서는 모든 모델에 동일한 24,576 토큰을 적용했다.

2.3 고정 입력 — 가장 중요한 통제

RAG 시스템은 질문에 대해 먼저 근거 문서를 검색하고, 그 근거를 읽어 답변을 만든다. 검색 단계가 모델마다 다른 근거를 가져오면 "답변이 나쁜 이유가 모델 때문인지 검색 때문인지" 알 수 없다.

그래서 검색 결과를 한 번만 수행해 파일로 동결하고, 10 개 모델 전부에 글자 하나까지 같은 입력을 주었다. 이 파일은 SHA-256 해시로 기록해 누구나 동일성을 검증할 수 있다.

동결 파일 해시: 14c011189fc156fe... (프롬프트 5 종 각각 별도 해시 기록)

2.4 평가 문항

실제 공공입찰 사업 5 곳의 공고 51 건에서 추출한 300 문항을 사용했다. 문항은 세 종류의 응답을 요구한다.

유형	요구하는 응답	예
답변	근거로 확정해 답한다	제안서 최대 분량은 몇 쪽인가
조건부 답변	조건을 달아 답한다	A 인 경우에만 가능하다
자료부족 안내	근거가 없음을 알린다	제공된 문서로는 확인되지 않는다

300 문항 중 권한 제한으로 차단된 5 건을 제외한 295 문항을 사용했다. 이 중 58 문항을 층화 추출해 사람이 직접 읽고 판정했으며, 나머지는 자동 계산으로 평가했다.

2.5 프롬프트 5 종 — 운을 배제하는 장치

같은 모델이라도 지시문(프롬프트)을 어떻게 쓰느냐에 따라 성능이 크게 달라진다. 지시문 하나로만 평가하면, 그 지시문이 우연히 잘 맞은 모델이 유리해진다.

이를 막기 위해 지시문을 5 종 준비하고 모든 모델을 5 번씩 평가했다. 지시문은 결과를 보기 전에 3 개 축(분량·배치·제시 방식)을 정해 기계적으로 작성했으며, 특정 모델의 약점을 겨냥한 문구는 넣지 않았다.

지시문	분량	규칙 배치	제시 방식
P1	294 자	형식 먼저	산문
P2	382 자	규칙 먼저	번호 목록
P3	401 자	형식 먼저	산문
P4	490 자	규칙 먼저	번호 + 예시
P5	565 자	형식 먼저	번호 + 역할 부여

보고서의 모든 수치는 5 종 평균이며, ± 뒤의 숫자는 5 종 사이의 표준편차다. 이 값이 클수록 지시문에 민감하다는 뜻이다.

총 실험 규모: 10 개 모델 × 295 문항 × 5 종 지시문 = 14,750 건의 답변을 생성했다.

3. 무엇을 쟀나

답변 하나하나를 세 갈래로 나누었다. 한 답변은 반드시 셋 중 하나에 속하며, 세 비율의 합은 100%다.

분류	뜻	사용자가 받는 것
정답	**결론이 맞고, 쓴 내용이 전부 근거 안에 있다**	**바로 쓸 수 있는 답**
환각	**근거에 없거나 근거와 어긋나는 내용이 있다**	**틀린 답 — 믿으면 손해**
무응답	질문에 대한 판단이 담기지 않았다	아무것도 없음

"환각"은 결론이 틀린 경우를 포함한다. 근거가 "불가"라고 하는데 "가능하다"고 답했다면, 그것이 곧 근거와 어긋나는 진술이기 때문이다.

3.1 판정 방법

답변을 읽고 두 가지를 순서대로 확인했다.

① 질문에 대한 판단이 있는가? — "할 수 없다", "가능하다" 같은 가부·방향 표현이 없으면 무응답으로 분류한다.

② 근거를 벗어난 문장이 있는가? — 하나라도 있으면 환각, 없고 결론이 맞으면 정답이다.

판정 기준은 답변을 보기 전에 문서로 확정했고, 판정 중에 바꾸지 않았다. 모델 이름과 지시문 종류는 가린 상태에서 판정했다.

3.2 환각의 네 가지 유형

환각은 국제 표준 분류(RAGTruth)에 따라 네 유형으로 나누어 기록했다.

유형	뜻	예
Evident Conflict	근거와 정면으로 어긋남	근거 "4 개사 이하" → 답변 "5 개사 가능"
Subtle Conflict	조건·범위가 미묘하게 어긋남	근거 "10 년 이상" → 답변 "정확히 10 년은 제외"
Evident Baseless	근거에 없는 내용을 지어냄	존재하지 않는 조항 번호·금액
Subtle Baseless	근거를 넘어선 조언을 덧붙임	"사전에 협의하시기 바랍니다"

Evident 는 근거와 나란히 놓으면 바로 보이고, Subtle 은 꼼꼼히 읽어야 보인다. Baseless 는 없는 내용을 만들어내는 쪽이라 특히 위험하다.

3.3 무응답의 네 가지 유형

무응답도 형태별로 나누어 기록했다. 왜 답을 못 받았는지에 따라 대응이 달라지기 때문이다.

유형	뜻	예
근거 반복	근거 문장을 옮기기만 하고 판단이 없음	"제안서는 PDF 로 제출하여야 한다"만 쓰고 끝
절차 서술	계산 방법만 쓰고 결과값이 없음	"공급가액과 인건비를 합산해야 한다"
파편	문장이 성립하지 않거나 조각만 출력	인용 번호·문서명만 나열
질문 반복	질문을 되풀이하고 끝남	질문 문장을 그대로 다시 씀

모델	무응답	근거 반복	절차 서술	파편	질문 반복
Qwen3-8B	**2.1**	**1.7**	**0.3**	**0.0**	**0.0**
Qwen3-14B	1.7	1.7	0.0	0.0	0.0
Qwen3-4B (현행)	**1.0**	**0.7**	**0.3**	**0.0**	**0.0**
Llama-3.1-8B	4.1	3.4	0.7	0.0	0.0
Gemma-3-4B	10.7	9.7	1.0	0.0	0.0
Kanana-1.5-2.1B	14.1	11.0	3.1	0.0	0.0
Kanana-1.5-8B	16.2	13.1	3.1	0.0	0.0
Qwen3-1.7B	11.4	8.3	3.1	0.0	0.0
Mi:dm-2.0-Mini	9.7	7.9	0.7	0.7	0.3
Gemma-3-1B	55.9	42.8	0.0	10.0	3.1

대부분 근거 반복이다. 질문에 답하지 않고 근거를 그대로 옮기는 형태이며, Gemma-3-1B 에 집중되어 있다. 현행 모델과 Qwen3-8B 는 무응답이 2% 이하로, 답을 내지 않는 경우가 거의 없다.

3.4 보조 지표

지표	무엇을 재나	계산 방법
인용 정확도	근거 번호를 제대로 다는가	답변에 쓴 번호가 실제 제공 범위 안인지 자동 대조
형식 하한	지시한 출력 형식을 지키는가	5 종 지시문 중 형식 준수율이 가장 낮은 값
정답 하한	지시문이 바뀌어도 보장되는 수준	5 종 지시문 중 정답률이 가장 낮은 값
응답 시간 (p50)	얼마나 기다려야 하나	도입 대상 노트북 CPU 실측. p50 은 중앙값으로, 질문 절반이 이 시간 안에 끝난다
응답 시간 (p95)	최악의 경우 얼마나 걸리나	상위 5% 경계. 근거가 긴 질문에서 시간이 튄다
메모리	설치 가능한가	측정 중 최대 점유량

형식 준수는 파이프라인이 답변에서 근거 번호를 뽑아내는 데 반드시 필요하다. 이 형식이 깨지면 답변 내용이 맞아도 시스템이 처리하지 못한다. 평균이 아니라 최저값을 쓰는 이유는, 특정 지시문에서만 무너지는 모델이 평균으로는 정상처럼 보이기 때문이다.

4. 결과

4.1 종합

모델	정답	환각	무응답	인용정확도	응답 p50	메모리
Qwen3-8B	**86.9 ± 4.7**	**11.0 ± 3.6**	**2.1**	**90.1**	**19.8s**	**10.73GB**
Qwen3-14B	86.9 ± 3.6	11.4 ± 2.6	1.7	89.6	—	—
Qwen3-4B (현행)	**76.9 ± 4.7**	**22.1 ± 4.5**	**1.0**	**82.9**	**10.8s**	**8.93GB**
Llama-3.1-8B	76.6 ± 4.5	19.3 ± 6.1	4.1	80.4	15.5s*	—
Gemma-3-4B	75.5 ± 7.7	13.8 ± 4.0	10.7	87.4	8.7s*	—
Kanana-1.5-2.1B	69.3 ± 12.2	16.6 ± 2.6	14.1	70.4	8.7s*	—
Kanana-1.5-8B	67.6 ± 6.7	16.2 ± 5.3	16.2	75.7	20.7s*	—
Qwen3-1.7B	56.2 ± 9.4	32.4 ± 9.4	11.4	79.3	5.7s*	—
Mi:dm-2.0-Mini	54.1 ± 21.7	36.2 ± 11.5	9.7	64.7	4.4s*	—
Gemma-3-1B	16.2 ± 4.7	27.9 ± 18.9	55.9	32.1	5.3s*	—

정답 + 환각 + 무응답 = 100%. ± 뒤는 지시문 5 종 사이의 표준편차. * 표시는 워크스테이션 실측에 비율을 적용한 추정값이며, 표시 없는 값은 도입 대상 노트북 직접 실측이다.

4.2 환각 유형별

모델	환각	Evident Conflict	Subtle Conflict	Evident Baseless	Subtle Baseless
Qwen3-8B	**11.0**	**3.4**	**6.2**	**0.0**	**1.4**
Qwen3-14B	11.4	5.5	5.5	0.0	0.3
Qwen3-4B (현행)	**22.1**	**14.1**	**5.2**	**0.7**	**2.1**
Llama-3.1-8B	19.3	10.0	6.6	0.3	2.4
Gemma-3-4B	13.8	6.9	6.6	0.0	0.3
Kanana-1.5-2.1B	16.6	8.3	3.4	1.7	3.1
Kanana-1.5-8B	16.2	11.4	4.8	0.0	0.0
Qwen3-1.7B	32.4	17.9	8.3	1.4	4.8
Mi:dm-2.0-Mini	36.2	30.7	4.5	0.0	1.0
Gemma-3-1B	27.9	18.3	2.1	6.2	1.4

Qwen3-8B 와 Qwen3-14B 는 Evident Baseless 가 0%다. 290 건 전부에서 존재하지 않는 조항이나 금액을 만들어내지 않았다. 현행 모델은 Evident Conflict 가 14.1%로, 근거를 정반대로 읽는 경우가 일곱 건에 한 건꼴이다.

4.3 형식·인용

모델	형식 준수(평균)	형식 하한	인용 정확도	수치 재현	원문 복사
Qwen3-8B	**100.0 ± 0.0**	**100.0**	**90.1 ± 3.0**	**52.4**	**2.0**
Qwen3-14B	100.0 ± 0.0	100.0	89.6 ± 4.3	53.0	0.3
Qwen3-4B (현행)	**99.0 ± 1.4**	**96.6**	**82.9 ± 3.5**	**47.2**	**5.3**
Llama-3.1-8B	98.6 ± 2.0	95.3	80.4 ± 7.5	53.8	6.6
Gemma-3-4B	79.8 ± 42.0	4.7	87.4 ± 3.7	54.1	3.3
Kanana-1.5-2.1B	82.4 ± 36.4	17.3	70.4 ± 5.7	58.2	18.4
Kanana-1.5-8B	80.2 ± 43.3	2.7	75.7 ± 11.0	48.0	2.9
Qwen3-1.7B	99.5 ± 0.3	99.3	79.3 ± 7.4	47.4	9.7
Mi:dm-2.0-Mini	68.6 ± 38.8	0.3	64.7 ± 10.4	48.6	6.1
Gemma-3-1B	16.3 ± 8.8	4.7	32.1 ± 10.8	33.6	29.9

형식 준수의 평균과 하한 차이에 주목할 필요가 있다. Gemma-3-4B 는 평균 79.8%지만 특정 지시문(P4)에서 4.7%로 무너진다. 네 개 지시문에서는 완벽하고 하나에서 붕괴하는 형태이므로, 평균은 이 모델의 실제 위험을 감춘다.

수치 재현율은 모든 모델이 33~58% 수준에 머물렀다. 어느 모델을 쓰더라도 금액·마감일 같은 숫자는 사람이 원문과 대조해야 한다는 뜻이다.

5. 모델 선정

측정한 값에서 결론으로 가는 과정을 두 단계로 나누었다. 먼저 "쓸 수 없는 모델"을 걸러내고, 남은 모델만 점수로 순위를 매겼다.

5.1 1 단계 — 관문

통과·탈락만 판정한다. 아래 세 조건 중 하나라도 어기면 점수 계산 대상이 아니다.

조건	기준	이유
라이선스	상업적 사용 가능	업무 도입 필수 요건
메모리	10GB 이하	도입 대상 PC 에서 다른 프로그램과 함께 사용 가능해야 함
형식 하한	90% 이상	파이프라인이 답변에서 근거 번호를 추출해야 함

모델	라이선스	메모리	형식 하한	판정
Qwen3-8B	Apache-2.0	10.73GB	100.0	탈락 — 메모리 초과
Qwen3-14B	Apache-2.0	15.00GB	100.0	탈락 — 메모리 초과
Qwen3-4B (현행)	**Apache-2.0**	**8.93GB**	**96.6**	**통과**
Llama-3.1-8B	**Llama 3.1**	**미측정**	**95.3**	**통과**
Gemma-3-4B	Gemma Terms	미측정	4.7	탈락 — 형식 하한 미달
Kanana-1.5-2.1B	Apache-2.0	미측정	17.3	탈락 — 형식 하한 미달
Kanana-1.5-8B	Apache-2.0	미측정	2.7	탈락 — 형식 하한 미달
Qwen3-1.7B	**Apache-2.0**	**미측정**	**99.3**	**통과**
Mi:dm-2.0-Mini	MIT	미측정	0.3	탈락 — 형식 하한 미달
Gemma-3-1B	Gemma Terms	미측정	4.7	탈락 — 형식 하한 미달

열 개 중 7 개가 탈락했다. 대부분 형식 하한 미달이며, 특정 지시문에서 출력 형식이 무너지는 모델들이다.

5.2 2 단계 — 점수

관문을 통과한 모델만 다섯 지표를 가중 합산해 순위를 매겼다. 각 지표는 0~100 으로 환산한 뒤 가중치를 곱했다.

지표	가중치	방향
정답률	3	높을수록 좋음
환각률	3	낮을수록 좋음
정답 하한	2	높을수록 좋음
인용 정확도	1	높을수록 좋음
응답 시간	1	낮을수록 좋음

순위	모델	점수	정답	환각	정답 하한	인용	응답 p50
1	**Qwen3-4B (현행)**	**88.4**	**76.9**	**22.1**	**62.1**	**82.9**	**10.8s**
2	Llama-3.1-8B	81.4	76.6	19.3	60.3	80.4	15.5s

순위	모델	점수	정답	환각	정답 하한	인용	응답 p50
3	Qwen3-1.7B	10.0	56.2	32.4	32.8	79.3	5.7s

5.3 3 단계 — 가중치를 바꿔도 결론이 같은가

가중치는 사람이 정하는 값이므로, 다르게 잡으면 순위가 바뀔 수 있다는 의문이 남는다. 이를 확인하기 위해 다섯 지표의 가중치를 0.5~3 범위에서 무작위로 바꾸어 3,000 번 다시 계산했다.

모델	1 위를 차지한 비율
Qwen3-4B (현행)	**100.0%**
Llama-3.1-8B	0.0%
Qwen3-1.7B	0.0%

결과: Qwen3-4B (현행)가 100.0%의 경우에서 1 위였다. 어떤 가중치를 적용하더라도 결론은 사실상 바뀌지 않는다.

부록 A. 실험 규모와 검증

항목	규모
생성한 답변	10 개 모델 × 295 문항 × 5 종 지시문 = 14,750 건
사람이 읽고 판정	10 개 모델 × 58 문항 × 5 종 지시문 = 2,900 건
자동 계산	14,750 건 전량
속도·메모리 측정	노트북 2 종 직접 측정, 워크스테이션 9 종 비교 측정
판정 검증	중복·누락·분류 정합성 23 개 항목 자동 검사 전체 통과

부록 B. 이 평가에서 다루지 않은 것

· 환각을 줄이는 방법 — 본 평가는 "어느 모델이 덜 틀리는가"까지만 다룬다. 환각 탐지·표시는 별도 시스템(형광펜 챗봇)이 담당한다.

· 권한 제어 — 권한 밖 자료가 근거에 섞였을 때 모델이 막아주는지 별도 실험한 결과, 10 종 중 7 종이 정보를 그대로 노출했다. 모델을 권한 방어선으로 쓸 수 없으며, 서버 권한 필터가 유일한 방어선이다.

· 검색 품질 — 어떤 근거를 가져올지는 검색 단계의 문제이며, 본 평가는 검색 결과를 고정해 모델만 비교했다.

부록 C. 한계

· 판정자가 1 인이다. 판정 기준을 문서로 고정하고 모델명을 가린 상태에서 판정했으나, 다른 사람이 판정하면 일부 결과가 달라질 수 있다.

· 사람 판정은 295 문항 중 58 문항 표본이다. 58 문항은 최종 평가용 문항 전량에 중간 점검용 문항을 유형 비율에 맞춰 보탠 것이다.

· 속도는 10 종 중 2 종만 도입 대상 노트북에서 직접 측정했고, 나머지는 워크스테이션 측정값에 비율을 적용해 환산했다.

· 문항 일부는 질문 표현이 모호해 모든 모델이 같은 형태로 답했다. 해당 문항은 모델 능력 차이를 반영하지 못한다.

가용 메모리를 11GB 이상 확보할 수 있다면 Qwen3-8B 도입이 가능하며, 정답률 76.9% → 86.9%, 환각률 22.1% → 11.0%의 개선이 기대된다. 메모리 절감을 위한 KV 캐시 압축(q8_0)은 절감 0.6GB 에 응답 시간 12~32% 증가로 권장하지 않는다.